Algoritmik Trading'de Makine Öğrenmesi: Akademik Kanıtlar, Yanılsamalar, Sızıntısız Doğrulama ve Mevcut Araştırma Hattına Entegrasyon Mimarisi (Ekim 2026)

Kapsam: Akademik Kanıtlar (Gu-Kelly-Xiu, TSFM, LLM, RL) • Meta-Labeling & HRP • Sızıntısız Doğrulama (CPCV, DSR, PBO, SPA) • Python Araç Seti & 3 Pilot Mimari | Ekim 2026

1. Yönetici Özeti ve Mevcut Araştırma Hattı İçin Mimari Konumlandırma

Kantitatif finans ve algoritmik işlem literatüründe makine öğrenmesi (ML), 2020–2026 döneminde iki zıt uç arasında keskin bir ayrışmaya sahne olmuştur. Bir tarafta sosyal medya, perakende gösterge pazarları ve ön-baskı (preprint) sunucularında ileriye dönük veri sızıntısı (look-ahead bias), işlem maliyeti ihmali ve çoklu test (data snooping) yanılsamalarıyla şişirilmiş "%90 doğruluk / Sharpe > 4.0" iddiaları yer alırken; diğer tarafta hakemli akademik çalışmalar ve kurumsal uygulayıcılar, **doğrudan ham fiyat yönü tahmininin (end-to-end price prediction) son derece düşük sinyal/gürültü oranına (R^2_{OOS} ≈ %0.1 – %0.4) sahip olduğunu**, buna karşılık ML'in mevcut sinyal üreten stratejilerin **üst katmanında (meta-labeling, rejim filtreleme, volatilite/risk tahmini ve hiyerarşik portföy ağırlıklandırma)** kullanıldığında istatistiksel olarak anlamlı ve maliyet sonrası kalıcı katma değer ürettiğini kanıtlamıştır (Gu, Kelly ve Xiu, 2020 - *Review of Financial Studies*; López de Prado, 2018 / QuantStrategy, Ağustos 2026).

Mevcut sisteminiz — GitHub Actions üzerinde koşan, ücretsiz veri kaynaklarını (`data.binance.vision` klines/aggTrades, `yfinance`, `Dukascopy`, `SEC EDGAR`) kullanan, **~942 TradingView stratejisini** kendi Pine yorumlayıcınızla yazarın orijinal ayarlarında test edip **"yayın sonrası (post-publication) uygulanabilir sınama döneminde net getiri > 0"** tek kapısından geçiren, ardından %10 yıllık oynaklık ölçekleme (volatility targeting), blok bootstrap p10 sıralaması ve korelasyon bazlı kopya ayıklama (deduplication) ile **20 gölge kitaba (paper-trade shadow books)** ve %10 zarar bütçesine bağlayan mimari — akademik literatürdeki en tehlikeli tuzak olan **parametre aşırı uyumunu (in-sample parameter overfitting)** zaten mimari olarak bertaraf etmektedir. Bu nedenle ML'i bu hattın içine "943. fiyat tahmin stratejisi" olarak eklemek yerine; (1) 942 stratejinin ürettiği birincil sinyallerin yanlış pozitiflerini (false positives) süzen bir **Meta-Labeling (İkincil Model)** katmanı, (2) stratejilerin hangi piyasa rejimlerinde çalışıp hangilerinde susturulacağını belirleyen bir **Gizli Markov / Değişim Noktası (HMM / Changepoint) Rejim** katmanı ve (3) tek kapıyı geçen stratejileri 20 gölge kitaba dağıtırken klasik ortalama-varyans veya basit sıralama yerine kuyruk bağımlılığını dikkate alan **Hiyerarşik Risk Paritesi / Nested Clustered Optimization (HRP / NCO)** katmanı olarak konumlandırmak en yüksek mühendislik getirisini sağlayacaktır (skfolio Docs, Mayıs 2026; PickMyTrade AI Quant Guide, 2026).

2. Kanıt Durumu: Akademik Literatür, Bağımsız Karşılaştırmalar ve Yanılsamalar

Aşağıdaki analizde her bir bulgunun kaynağı [Hakemli Makale], [Tanınmış Uygulayıcı / Açık Kaynak Benchmark] veya [Pazarlama / Reklam İddiası] etiketiyle sınıflandırılmıştır.

2.1. ML ile Getiri Tahmininde Gerçekçi Beklenti, Maliyet Sonrası Alfa ve Yayın Sonrası Bozulma

- **Gu, Kelly ve Xiu (2020) ve Sonrası Gerçekçi R^2 Sınırı [Hakemli Makale]:** Modern finansal makine öğrenmesinin temel referansı olan **Gu, Kelly ve Xiu (Mayıs 2020, *The Review of Financial Studies*, 33(5), 2223–2273)** (Oxford Academic Linki; Tam Metin PDF), ABD borsalarındaki 30.000 hisse ve 94 firma karakteristiği (toplam ~920 özellik etkileşimi) üzerinde 1957–2016 verisiyle doğrusal modelleri, cezalı regresyonları (Elastic Net), ağaç tabanlı modelleri (Random Forest, GBRT) ve sinir ağlarını (NN1–NN5) karşılaştırmıştır. En iyi performans gösteren sığ sinir ağları (NN3–NN4) ve gradyan artırımlı ağaçların **aylık**

örneklem dışı (out-of-sample) R^2 değeri yalnızca %0.40 (%0.33–%0.40) düzeyindedir (buna karşılık sıradan en küçük kareler OLS modeli aşırı uyum nedeniyle negatif R^2 üretmiştir) (QuantMemo, Temmuz 2026). Kritik bulgu şudur: ML modelleri sihirli yeni faktörler icat etmemekte, mevcut **momentum, likidite ve volatilite** değişkenleri arasındaki doğrusal olmayan (non-linear) etkileşimleri yakalamaktadır.

- **İşlem Maliyetleri Sonrası Kalan Alfa (Avramov, Cheng ve Metzker, 2023 vs. Azevedo, Hoegner ve Velikov, 2023–2025) [Hakemli Makale]: Avramov, Cheng ve Metzker (2023, *Journal of Financial Economics*)**, Gu-Kelly-Xiu tipi ML modellerinin ürettiği brüt alfanın büyük ölçüde mikro-sermayeli (micro-cap), likiditesi sığ, açığa satışı pahalı ve finansal sıkıntıdaki hisselerde yoğunlaştığını; gerçekçi işlem maliyetleri ve yüksek portföy devir hızı (turnover) düşüldüğünde net alfanın dramatik biçimde eridiğini göstermiştir. **Azevedo, Hoegner ve Velikov (*The Expected Returns on Machine-Learning Strategies*, AFA / Journal of Finance sunumu, 2023–2025)** (AFA JoF Linki) ise 320 yayınlanmış anomaliyi 9 farklı ML mimarisiyle birleştirerek üç sönümlenme etkisini (yayın sonrası bozulma, ondalık fiyatlama sonrası likidite değişimi ve işlem maliyetleri) aynı anda ölçmüştür: Tüm anomali hayvanat bahçesinin (anomaly zoo) beklenen net getirisi ayda ~20 baz puana kadar düşerken, ML modellerinin işlem maliyetinden sonra pozitif net alfa üretebilmesi **ancak işlem maliyetini doğrudan amaç fonksiyonuna (cost-mitigation / turnover penalization) dahil etmekle ve değer ağırlıklı (value-weighted) likit evrende kalmakla** mümkün olmaktadır.
- **Kripto ve Yüksek Frekansta Güncel Bulgular (2025–2026) [Hakemli Makale & Ön-Baskı]:** Kripto para piyasalarında **Mayıs 2026 tarihli *"Machine Learning-Based Bitcoin Trading Under Transaction Costs" (arXiv:2606.00060) (arXiv Linki, 19 Mayıs 2026) ve Eylül 2026 tarihli "Research on Machine Learning High-Frequency Trading Strategy of Cryptocurrency Based on Transaction Cost-Aware Filtering"*** (ResearchGate Linki, Eylül 2026) çalışmaları, saatlik ve gün içi BTC/USDT tahminlerinde ham yön doğruluğunun %51–%53 bandında kaldığını; modelin her sinyalde işlem yapması halinde 4–10 bps'lik borsa komisyonu ve kayma (slippage) yüzünden kesin zarar ettiğini, **yalnızca beklenen hareket büyüklüğünün işlem maliyetini belirgin bir eşikle aştığı durumlarda işlem açan "maliyet-duyarlı filtreleme" (transaction cost-aware filtering / meta-labeling)** kullanıldığında pozitif net Sharpe elde edildiğini kanıtlamıştır.
- **Yayın Sonrası Bozulma (McLean ve Pontiff, 2016; Chen ve Zimmermann, 2022–2025) [Hakemli Makale]: McLean ve Pontiff (Şubat 2016, *Journal of Finance*, 71(1), 5–32)** (RePEc Linki), akademik olarak yayınlanan 97 stratejinin getirisinin örneklem içi (in-sample) dönemden sonra %26 (istatistiksel aşırı uyum payı), **yayınlandıktan sonra (post-publication) ise %58 oranında eridiğini** (arbitrajcıların stratejiyi öğrenip fiyatlaması nedeniyle) göstermiştir. **Chen, Lopez-Lira ve Zimmermann (2025/2026, *"Does Peer-Reviewed Research Help Predict Stock Returns?"*, arXiv:2212.10317v7)** (arXiv Linki, 2025/2026) ise bu bulguyu doğrulayarak örneklem dışı bozulmanın ortalama %32–%60 bandında gerçekleştiğini göstermektedir. **Sizin sisteminizdeki "TradingView stratejisinin yayın tarihinden sonraki uygulanabilir sınama döneminde net > 0 olma" kapısı, tam olarak bu McLean-Pontiff bozulmasını doğrudan test eden en doğru mühendislik filtresidir.**

2.2. Derin Öğrenme ve Zaman Serisi Foundation Modelleri (TimesFM, Chronos, Moirai) vs. Klasik Modeller (GBM, Lineer)

Son iki yılda Google (**TimesFM / TimesFM-2.5**), Amazon (**Chronos / Chronos-2**) ve Salesforce (**Moirai / Moirai-2.0**) tarafından geliştirilen önceden eğitilmiş Zaman Serisi Foundation Modelleri (TSFM) ile klasik derin öğrenme mimarileri (LSTM, Temporal Fusion Transformer - TFT, PatchTST, iTransformer), tablosal gradyan artırımlı ağaçlarla (**LightGBM, XGBoost, CatBoost**) bağımsız finansal testlerde karşılaştırılmıştır:

- **Zeng ve ark. (2023, AAAI Oral - *"Are Transformers Effective for Time Series Forecasting?"*) [Hakemli Makale]:** Tek katmanlı basit bir doğrusal modelin (**DLinear**), karmaşık Transformer mimarilerini (Informer, Autoformer, FEDformer) standart uzun ufuklu zaman serisi testlerinin tamamına yakınında yendiğini, çünkü öz-dikkat (self-attention) mekanizmasının permütasyon-değişmez (permutation-invariant) yapısı

nedeniyle zamansal sıra bilgisini gürültülü serilerde kaybettiğini kanıtlamıştır (PickMyTrade Benchmark Özeti, 2026).

- **Noguer i Alonso ve Pereira Franklin (Haziran 2026, AI Finance Institute - *"Pretrained Time-Series Foundation Models for Financial Return Forecasting"*) [Tanınmış Uygulayıcı / Akademik Benchmark]:** TimeGPT, **TimesFM-2.5**, **Moirai-2.0**, **Chronos** ve **Chronos-2** modellerini 5 likit ABD hissesi (AAPL, AMZN, GOOG, JPM, META) üzerinde NBEATS, NHITS, PatchTST, iTransformer ve rastgele yürüyüş (random walk) ile yuvarlanan pencerede (rolling-origin) karşılaştırmıştır. Sonuç çarpıcıdır: **10 varlık/görev kombinasyonunun yalnızca 2'sinde rastgele yürüyüşe kıyasla istatistiksel olarak anlamlı bir üstünlük çıkmıştır**; yazarlar TSFM'lerin "fiyat yönü ve getiri tahmini için güvenilir alfa motorları olmadığını", ancak **volatilite (oynaklık) tahmini ve mevsimsellik ayrıştırmasında** güçlü sıfır-atış (zero-shot) önsel (prior) sağladığını açıkça raporlamıştır (PickMyTrade AI Quant Guide, 2026).
- **Rahimikia ve ark. (Mart 2026, Frontiers of Factor Investing Konferansı - *"Re(Visiting) Time Series Foundation Models in Finance"*) [Hakemli Konferans Bildirisi]:** 2001–2023 yılları arasında tüm ABD hisseleri üzerinde 5, 21, 252 ve 512 günlük pencerelerle yapılan kapsamlı karşılaştırmada, **ağaç tabanlı topluluk modellerinin (CatBoost, LightGBM, XGBoost) hem doğrusal modelleri hem de derin sinir ağı / foundation model mimarilerini istikrarlı biçimde yendiği** (yön doğruluğu ~%51+, en yüksek risk-uyarlanmış Sharpe performansı CatBoost/GBDT ailesinde) gösterilmiştir (Lancaster University FoFI PDF, Mart 2026).

2.3. Büyük Dil Modelleri (LLM): Duygu Analizi, Ajan Tabanlı Trading (2024–2026) ve Eğitim Verisi Sızıntısı

- **Haber/Başlık Duygu Analizi (Lopez-Lira ve Tang, 2023–2024) [Hakemli / Çalışma Makalesi]:** Şirket haber başlıklarının LLM'ler ile puanlanarak ertesi gün açılışında yapılan long-short hisse stratejilerinin özellikle küçük ölçekli hisselerde anlamlı alfa ürettiği gösterilmiştir (TradingAgents / arXiv, Haziran 2025). Ancak bu alfa, haberin yayınlandığı ilk birkaç dakika/saat içinde kurumsal düşük gecikmeli (low-latency) NLP sistemleri tarafından arbitraj edilmektedir.
- **Ajan Tabanlı LLM Çerçeveleri (FinMem, TradingAgents, FinRobot, AlphaGPT) ve Yanılsamalar [Akademik Eleştiri vs. Pazarlama]:** 2024–2026 arasında yayımlanan **FinMem** (GitHub) ve **TradingAgents** (arXiv:2412.20138, Haziran 2025) gibi çoklu ajan (analist, araştırmacı, risk yöneticisi, trader ajanları) çalışmaları, geriye dönük testlerde yüksek getiriler raporlamaktadır. Ancak **Mart 2026 tarihli *"Large Language Model Agent in Financial Trading: A Survey"* (arXiv:2408.06361v2)** (arXiv Linki, 1 Mart 2026) çalışmasının ortaya koyduğu üzere, LLM trading çalışmalarının büyük çoğunluğu üç ölümcül kusur taşımaktadır:
- **Ön-Eğitim Zaman Sızıntısı (Pre-training Cutoff Look-Ahead Bias):** 2023 veya 2024'te eğitilmiş bir LLM'e (ör. GPT-4 veya Llama-3) 2021–2023 dönemindeki Apple veya Nvidia haberlerini verip "al/sat" dediğinizde, model o şirketin gelecekte ne kadar büyüdüğünü ağırlıklarında (weights) zaten ezbere bilmektedir! Modelin eğitim kesim tarihinden (knowledge cutoff) önceki her türlü backtest **tamamen geçersizdir**.
- **Kısa ve Tek Rejimli Test Penceresi:** Ajan makalelerinin çoğu yalnızca 3–12 aylık tek bir boğa piyasası diliminde (ör. 2023–2024 teknoloji rallisi) birkaç popüler hisse (TSLA, NVDA, AAPL, BTC) üzerinde test edilmektedir.
- **API Maliyeti ve Gecikme:** 942 strateji ve binlerce bar için çoklu LLM ajanı çalıştırmak yüksek token maliyeti ve saniyeler süren gecikme yaratır. *(LLM'lerin kantitatif hattaki gerçek yeri canlı sinyal üretmek değil; araştırma kodunu yazmak ve SEC 13F/8-K metinlerini yapılandırılmış tablosal özelliklere dönüştürmektir).*

2.4. Pekiştirmeli Öğrenme (RL) ile Trading ve Portföy: Canlıda İşe Yarayan Örnek Var mı?

- **Simülasyon-Gerçeklik Uçurumu (The Reality Gap) [Hakemli Makale]: FinRL / FinRL-X** (GitHub, 2026; FinRL Benchmark arXiv, Mayıs 2025) kütüphanesi akademik dünyada PPO, SAC, TD3 ve DDQN algoritmalarını finansal ortamlarda standartlaştırmış olsa da, **Nisan 2026 tarihli *"Realistic Market Impact Modeling for Reinforcement Learning"* (arXiv:2603.29086v2)** (arXiv Linki, 4 Nisan 2026) ve **Ekim 2026 tarihli *"Evolution and Challenges of Reinforcement Learning in Intraday Algorithmic Trading: A Systematic Literature Review"* (MDPI, 11 Ekim 2026)** (MDPI Linki) makaleleri, RL ajanlarının canlı piyasada neden başarısız olduğunu net biçimde belgelemiştir:
- Standart RL ortamları (Gymnasium), sabit işlem maliyeti (ör. 10 bps) ve sıfır piyasa etkisi (zero market impact) varsayar; RL ajanı piyasa sinyali öğrenmek yerine **simülatörün doldurma (fill) kurallarındaki kusurları ve tarihsel gürültüyü ezberleyerek** gerçek hayatta imkânsız sıklıkta işlem açar.
- Rastgele tohum (random seed) değiştiğinde bile tamamen zıt politikalar üreten aşırı kararsızlık (**Henderson ve ark., 2018; Vetrin ve Koberg, 2024** (CRM PDF, 2024)) nedeniyle, **doğrudan yön tahmin eden perakende/orta frekanslı RL modellerinin canlıda istikrarlı çalıştığına dair doğrulanmış bağımsız kanıt yoktur**.
- **RL'in Canlıda Gerçekten İşe Yaradığı Tek Alan:** Büyük kurumsal emirlerin emir defterine parçalanarak en düşük kaymayla iletilmesi (**Optimal Execution / Almgren-Chriss uzantıları**) ve yüksek frekanslı piyasa yapıcılığında (HFT Market Making) stok (inventory) kontrolüdür (arXiv RL Review, Aralık 2025).

Tablo 1: Algoritmik Trading'de Makine Öğrenmesi Yaklaşımlarının Kanıt Durumu ve Gerçekçilik Matrisi (Ekim 2026)

Yaklaşım / Model Ailesi	Kanıt Sınıfı ve Ana Referanslar	Örneklem Dışı (OOS) Gerçekçi Beklenti	Maliyet Sonrası Alfa ve Canlı Dayanıklılık	En Yaygın Yanılsama / Hata Kaynağı	Bizim Sistem (942 Strateji + 20 Gölge Kitap) İçin Karar
Gradyan Artırımlı Ağaçlar (LightGBM, XGBoost, CatBoost)	**[Hakemli Makale & Uygulayıcı Standardı]** (Gu et al., 2020; Rahimikia et al., Mart 2026)	Aylık $R^2_{OOS} \approx \%0.2 - \%0.4$; yön doğruluğu %51–%53; meta-etiketlemede F1 ve Precision artışı	Düşük devir hızı veya maliyet-duyarlı eşik (meta-labeling) ile **Yüksek**; CPU'da saniyeler içinde eğitilir	Durağan olmayan (non-stationary) ham fiyat serisi beslemek ve örtüşen etiketlerle (overlapping labels) K-Fold yapmak	**BİRİNCİL TERCİH:** Meta-labeling, rejim sınıflandırma ve lider seçimi için ana motor olarak kullanılmalı
Cezalı Doğrusal Modeller (Ridge, Lasso, Elastic Net)	**[Hakemli Makale]** (Gu et al., 2020; Azevedo et al., 2025)	Çok yüksek gürültülü ortamlarda aşırı uyuma karşı en dirençli temel çizgi (baseline)	Düşük/Orta; doğrusal olmayan etkileşimleri kaçırır ancak canlıda sürpriz çöküş yaşamaz	Çoklu doğrusal bağlantı (multicollinearity) altında Lasso'nun rastgele değişken seçmesi	**TEMEL ÇİZGİ (BASELINE):** Her GBDT modeli mutlaka Ridge/Lojistik Regresyon temel çizgisini yenmek zorunda tutulmalı
Klasik Derin Öğrenme (LSTM, GRU, CNN, TFT, PatchTST)	**[Hakemli Makale]** (Zeng et al., 2023 AAAI; Azevedo et al., 2025)	Çok geniş kesitsel (cross-sectional, >5.000 hisse) veya L2/L3 orderbook verisi yoksa GBDT'nin gerisinde kalır	Yüksek işlem sıklığı ve hiperparametre hassasiyeti nedeniyle maliyet sonrası alfa çoğunlukla erir	`MinMaxScaler` veya pencere kaydırmada tüm veri setini tek seferde ölçekleyerek gelecek bilgisi sızdırmak	**ÖNERİLMEZ:** GitHub Actions CPU kısıtında eğitim maliyeti yüksek, tablosal özniteliklerde LightGBM'e üstünlüğü yok

Yaklaşım / Model Ailesi	Kanıt Sınıfı ve Ana Referanslar	Örneklem Dışı (OOS) Gerçekçi Beklenti	Maliyet Sonrası Alfa ve Canlı Dayanıklılık	En Yaygın Yanılsama / Hata Kaynağı	Bizim Sistem (942 Strateji + 20 Gölge Kitap) İçin Karar
Zaman Serisi Foundation Modelleri (TimesFM-2.5, Chronos-2, Moirai-2.0)	**[Bağımsız Akademik Benchmark]** (Noguer i Alonso & Franklin, Haziran 2026; arXiv, Mayıs 2026)	**Fiyat yönü tahmininde rastgele yürüyüşten farksız** (10 testin 8'inde anlamsız); **volatilite ve hacim tahmininde başarılı**	Doğrudan yön sinyali olarak **Sıfır/Negatif**; pozisyon boyutlama için volatilite girdisi olarak **Olumlu**	Sıfır-atış (zero-shot) modelin ön-eğitim derleminde hedef varlığın geçmiş yıllarının zaten yer alması	**YALNIZCA VOLATİLİTE İÇİN:** Fiyat yönü için kullanılmamalı; gerekirse HAR-RV / GARCH yanında volatilite önseli olarak test edilebilir
Büyük Dil Modelleri (LLM Duygu Analizi & Ajanlar: FinMem, TradingAgents)	**[Ön-Baskı & Akademik Eleştiri]** (arXiv Survey, Mart 2026; TradingAgents, Haziran 2025)	Eğitim kesim tarihinden (cutoff) sonraki gerçek örneklem dışında çok düşük ve yüksek maliyetli	Haber duygu alfası dakikalar içinde erir; çoklu ajan çerçevelerinin canlı kanıtı **doğrulanamadı**	**Pre-training Look-Ahead Bias:** Modelin 2021–2024 backtestinde hangi şirketin kazandığını önceden bilmesi	**CANLI SİNYALDE KULLANILMAMALI:** Yalnızca çevrimdışı kod/strateji ayrıştırma ve metin madenciliği için yardımcı araç
Pekiştirmeli Öğrenme (RL: FinRL, PPO, SAC, DDQN)	**[Hakemli Eleştiri]** (arXiv Market Impact, Nisan 2026; MDPI Review, Ekim 2026)	Yön tahmininde aşırı kararsız (seed bağımlı); yalnızca emir yürütme (execution) ve piyasa yapıcılıkta kanıtlı	Simülasyonda çok yüksek, canlıya geçildiğinde kayma ve piyasa etkisiyle **Çöküş (Reality Gap)**	Sabit komisyonlu simülatörün içindeki mikro-yapı açıklarını (fill rules) gerçek alfa sanıp ezberlemesi	**KESİNLİKLE KAÇINILMALI:** Günlük/saatlik sinyal ve portföy yönetiminde harcanan emeğe kıyasla canlı başarısı en düşük yöntem

3. Mevcut Araştırma Hattına Değer Katan 6 ML Katmanı ve TradingView "ML" İncelemesi

3.1. Meta-Labeling (Marcos López de Prado): Birincil Sinyali Filtreleme ve Boyutlama

- **Yöntem:** Marcos López de Prado'nun *Advances in Financial Machine Learning* (2018, Bölüm 3.6) kitabında tanımladığı **Meta-Labeling** (QuantStrategy, 6 Ağustos 2026; Hudson & Thames PDF), işlem yönü kararını (**Side:** Long / Short) işlem büyüklüğü ve güven kararından (**Size:** $0 \le w \le 1$) tamamen ayırır. Sizin sisteminizde 942 TradingView stratejisinden her biri "Birincil Model"dir (Primary Model). Birincil model t anında bir giriş sinyali ürettiğinde, **İkincil Model (Meta-Model: örneğin sığ bir LightGBM veya Lojistik Regresyon)** devreye girer ve şu soruyu yanıtlar: *"Mevcut piyasa rejiminde, volatilitede ve emir akışında bu birincil sinyalin işlem maliyetleri düşüldükten sonra kâr hedefine (Triple-Barrier üst bariyerine) ulaşma olasılığı $P(y_{meta} = 1)$ nedir?"* Eğer $P < \tau$ (ör. 0.55) ise işlem iptal edilir (veya olasılığa göre pozisyon boyutu $w = 2P - 1$ ya da kesirli Kelly ile ölçeklenir).
- **Kanıt [Hakemli & Uygulayıcı]:** Birincil stratejiler genellikle yüksek duyarlılığa (Recall) sahiptir ancak yatay/ters rejimlerde çok sayıda yanlış pozitif (False Positive - Tip I hata) üretir. Meta-labeling, yanlış pozitifleri eleyerek kesinliği (Precision) ve **F1 skorunu** yükseltir, işlem sayısını ve komisyon/kayma erimesini %30–%60 azaltır ve stratejinin Sharpe oranını anlamlı biçimde artırır (mlfinpy Docs, 2026; Mental Momentum Research, Haziran 2026).

- **Risk:** Meta-modelin kendi içinde aşırı uyum yapması (özellikle birincil stratejinin toplam işlem sayısı N < 200 ise). Bu riski önlemek için her stratejiye ayrı bir ML modeli eğitmek yerine, benzer strateji aileleri (ör. tüm trend takipçileri için tek bir havuzlanmış/pooled meta-model) üzerinde **Purged K-Fold** ile sığ ağaçlar (`max_depth=3`, `min_child_samples=50`) eğitilmelidir.

3.2. Rejim Tespiti (HMM, Changepoint, Volatilite Rejimleri) ile Strateji Açma/Kapama

- **Yöntem:** Piyasalar durağan değildir; düşük volatiliteli trend, yüksek volatiliteli çöküş ve yatay (mean-reverting) rejimler arasında geçiş yapar. İki temel denetimsiz/istatistiksel yöntem öne çıkar:
- **Gizli Markov Modelleri (`hmmlearn` - GaussianHMM) veya Markov-Switching GARCH:** Getiri, gerçekleşen volatilite (Yang-Zhang / Garman-Klass) ve hacim/fonlama oranı değişimlerinden gizli durumu ($S_t \in$ {Sakin Trend, Yatay/Sıkışma, Stres/Kriz}) tahmin eder (PickMyTrade Guide, 2026).
- **Çevrimiçi Değişim Noktası Tespiti (BOCPD - Bayesian Online Changepoint Detection):** Yapısal kırılmaları gerçek zamanlı yakalar *(Dikkat: `ruptures` kütüphanesindeki PELT algoritması tüm seriyi baştan sona okuyan çevrimdışı/offline bir yöntemdir; canlı sinyalde ileriye dönük sızıntı yapmaması için yalnızca genişleyen pencerede veya BOCPD/filtrelenmiş HMM olasılıklarıyla kullanılmalıdır).*
- **Kanıt ve Bizim Sisteme Uygulama:** Trend takip eden Pine stratejileri düşük/orta volatiliteli yönlü rejimlerde para kazanırken yatay rejimlerde doğranır (whipsaw); ortalamaya dönüş (RSI/Bollinger) stratejileri ise yatay rejimde kazanıp güçlü kırılmalarda büyük zarar yazar. 20 gölge kitaptaki stratejileri rejim olasılıklarına göre koşullandırmak (veya rejim durumunu doğrudan Meta-Labeling modeline bir öznitelik olarak vermek), %10 zarar bütçesini korumada en etkili kalkandır.

3.3. Strateji Seçimi, Ensemble ve 20 Gölge Kitap İçin Portföy Ağırlıkları (HRP / HERC / NCO)

- **Yöntem:** Tek kapıyı geçen aday stratejilerden oluşan sanal havuzu **20 gölge kitaba (shadow books)** dağıtırken, eşit ağırlık (1/N) veya tekil sıralama puanı kullanmak gizli bir tehlike barındırır: TradingView'daki 942 stratejinin önemli bir kısmı farklı isimler taşısa da aslında aynı gizli faktöre (örneğin gizli bir MACD/EMA kesişimine veya BTC beta'sına) maruzdur. Klasik Markowitz (Ortalama-Varyans) optimizasyonu ise kovaryans matrisinin tersini (Σ^{-1}) aldığı için birbirine yakın stratejilerde aşırı uç ve kararsız ağırlıklar üretir (**"Markowitz'in Laneti"**) (NVIDIA Technical Blog; ResearchGate, Ağustos 2026).
- **Hiyerarşik Risk Paritesi (HRP - López de Prado, 2016) ve HERC / NCO (`skfolio`):** Stratejilerin günlük net getiri serileri arasındaki korelasyon uzaklığı ($d_{i,j} = \sqrt{(0.5 \cdot (1 - \rho_{i,j}))}$) üzerinden hiyerarşik kümeleme ağacı (dendrogram) kurar, matrisi yarı-köşegenleştirir (quasi-diagonalization) ve risk bütçesini yukarıdan aşağıya ikiye bölerek (recursive bisection) dağıtır (Wikipedia HRP; skfolio Docs, Mayıs 2026).
- **20 Gölge Kitaba Somut Uygulama:** Tek kapıyı geçen (örneğin 80–150) stratejinin yayın sonrası net getiri matrisine **Ward bağlantılı Hiyerarşik Kümeleme** uygulanarak tam **20 küme (cluster)** oluşturulur. Her kümenin içinden blok bootstrap p10 / Deflated Sharpe skoru en yüksek olan **1 temsilci strateji** seçilerek 20 gölge kitap belirlenir (böylece 20 kitabın birbirinden yapısal olarak farklı olması garanti edilir). Ardından bu 20 gölge kitabın sermaye ağırlıkları `skfolio.optimization.HierarchicalRiskParity` (veya CVaR-bazlı HERC) ile aylık olarak dengelenir.

3.4. Pozisyon Boyutlama ve Risk/Volatilite Tahmini

- **Yöntem:** Sisteminizde halihazırda mevcut olan **"%10 oynaklık ölçekleme" (volatility targeting)** mekanizması, matematiksel olarak $\text{Boyut}_t = \sigma_{\text{hedef}} / \hat{\sigma}_{t+1}$ formülüne dayanır. Getiri yönü tahmin edilemezken, **volatilitenin kümelenme (volatility clustering) ve uzun hafıza özelliği nedeniyle $\hat{\sigma}_{t+1}$ yüksek doğrulukla ($R^2_{OOS} > \%35 - \%50$) tahmin edilebilir**.
- **Kanıt [Hakemli Makale]: Corsi (2009, *Journal of Financial Econometrics*)** tarafından geliştirilen **HAR-RV (Heterogeneous Autoregressive model of Realized Volatility)** — günlük, haftalık ve aylık gerçekleşen

volatilite bileşenlerinin doğrusal/Ridge kombinasyonu veya üzerine eklenen hafif bir LightGBM Quantile (kuantil) modeli — basit 20 günlük standart sapmaya kıyasla ani volatilite patlamalarına çok daha hızlı uyum sağlar, portföyün gerçekleşen volatilitesini %10 hedefine sıkıca çiviler ve sol kuyruk riskini (Max Drawdown / %10 zarar bütçesi aşımını) anlamlı ölçüde düşürür.

3.5. Copy Trading'de Lider Seçimi (Faz 2 İçin ML Sınıflandırıcı)

- **Yöntem:** Bir önceki araştırmada incelenen copy trading liderlerinin (Hyperliquid cüzdanları/kasaları, Binance liderleri, MQL5 sinyalleri) gelecekteki 30–90 günlük örneklem dışı net getirisini (veya çökmeme olasılığını) tahmin etmek için kesitsel (cross-sectional) bir LightGBM sıralama (`lambdarank` veya binary classification) modeli kurulmasıdır.
- **Kanıt [Hakemli Makale]:** Akademik çalışmalar (**Pelster ve Hofmann, 2018** (ResearchGate); **Röder ve Walter, 2019** (INFORMS)), liderin **son 30 günlük ham ROI'sinin gelecekteki performansla negatif korelasyonlu** (ortalamaya dönüş) olduğunu kanıtlamıştır. Buna karşılık gelecekteki başarıyı pozitif tahmin eden özellikler şunlardır: (1) **Eğilim Etkisi Oranı (Disposition Effect Ratio):** Liderin zarardaki pozisyonları tutma süresinin kârdaki pozisyonları tutma süresine oranı (düşük olmalı; zararı hızlı kesmeli), (2) **Özsermaye/Bakiye Sarkma Oranı (Floating Equity DD / Realized Balance DD):** Martingale yapmadığının kanıtı, (3) **Kaldıraç İstikrarı:** Zarar sonrası pozisyon boyutunu büyütmeme (anti-martingale), (4) **Hesap Yaşı ve Kendi Sermayesi (Skin in the Game)**.

3.6. TradingView'daki "ML" Göstergelerinin Teknik Denetimi: `jdehorty` Lorentzian Classification ve Kernel Regression

TradingView kütüphanesinde en çok kopyalanan açık kaynaklı "makine öğrenmesi" betiği olan **`jdehorty` — *"Machine Learning: Lorentzian Classification"*** (GitHub Gist Kaynak Kodu; PickMyTrade Analizi, Temmuz 2026) ve beraberinde kullanılan **Nadaraya-Watson Rational Quadratic Kernel** göstergesinin satır satır kaynak kodu incelendiğinde şu teknik gerçekler ortaya çıkmaktadır:

1. **Gerçekten Makine Öğrenmesi mi?** Algoritma bir sinir ağı veya gradyan artırımlı ağaç değildir; 5 adet klasik teknik göstergenin (varsayılan: `RSI(14)`, `WT(10,11)`, `CCI(20)`, `ADX(20)`, `RSI(9)`) normalize edilmiş değerlerinden oluşan 5 boyutlu uzayda çalışan **parametrik olmayan yaklaşık K-En Yakın Komşu (Approximate K-Nearest Neighbors - ANN)** algoritmasıdır (Gist Satır 82–150). Öklid uzaklığı yerine aykırı değerleri (outliers) logaritmik olarak bastıran **Lorentzian uzaklığını** kullanır:

$$\mathbf{d(x_t, x_i) = \Sigma_{m=1..5}\, ln(1 + |f_{m,t} - f_{m,i}|)}$$

2. **Kritik Kusur 1 — Eğitim Etiketi Tanımında 4 Barlık Doğrudan İleriye Dönük Sızıntı (Look-Ahead Bias in `y_train_array`):** Betiğin 210–214. satırlarında eğitim etiketi şu şekilde tanımlanmıştır: `pinescript src = settings.source y_train_series = src[4] < src[0] ? direction.short : src[4] > src[0] ? direction.long : direction.neutral array.push(y_train_array, y_train_series)` Pine Script'te her barda `y_train_array` dizisine o barın `y_train_series` değeri (`src[4]` ile `src[0]` karşılaştırması) eklenir. Dikkat edilirse `i` indeksli tarihsel bir barın dizideki etiketi, o barın **4 bar önceki fiyatıyla (`src[4]`) kendi kapanışını (`src[0]`)** karşılaştırır! Yani tarihsel komşu `i` seçildiğinde, o komşunun *gelecekteki* 4 barlık getirisi değil, **kendi geçmiş 4 barlık momentumu (`close[i] > close[i-4]`)** etiket olarak alınmaktadır! Başka bir ifadeyle algoritma "geçmişte RSI/CCI bu seviyelerdeyken sonraki 4 barda ne oldu?" sorusunu değil, **"geçmişte RSI/CCI bu seviyelerdeyken o ana kadarki son 4 barda fiyat ne yöne gitmişti?"** sorusunu oylamaktadır; bu da onu gelecek tahmincisinden ziyade karmaşık bir momentum/trend takip filtresine dönüştürmektedir (Gist Satır 211–263).

3. **Kritik Kusur 2 — Tekdüze Olmayan Komşu Seçimi (`lastDistance` Kısıtı):** Standart KNN tüm geçmişteki en yakın K komşuyu bulup sıralarken, Pine Script'in çalışma süresi sınırına takılmamak için `jdehorty` döngü içinde `if d >= lastDistance and i % 4` şartını kullanır (Gist Satır 256). Bu şart, yeni eklenen her komşunun uzaklığının bir öncekinden *daha büyük veya eşit* olmasını zorunlu kılar ve `predictions` dizisi `neighborsCount` (8) sınırını aştığında ilk elemanı atıp `lastDistance`'ı dizinin %75'lik dilimine eşitler. Sonuç olarak seçilen 8

komşu gerçekte en yakın komşular değil, `maxBarsBack` (2000 bar) penceresinin sonuna yakın ve kronolojik tarama sırasına bağımlı yarı-rastgele bir alt kümedir.

4. **Yeniden Boyama (Repainting) Durumu:** `jdehorty`'nin kendi Nadaraya-Watson Rational Quadratic Kernel filtresi yalnızca geçmiş barları (`i = 0..size`) ağırlıklandırdığı için **bar kapandıktan sonra yeniden boyama (historical repainting) yapmaz** (ancak `useWorstCase = false` iken bar içinde/intrabar sinyal yanıp sönebilir). Buna karşılık TradingView'daki diğer popüler **"Nadaraya-Watson Envelope [LuxAlgo]"** gibi uç nokta (endpoint) yerine merkezlenmiş (centered/smooth) çekirdek kullanan betikler gelecekteki barları hesaba kattığı için **ağır biçimde yeniden boyama (repainting / look-ahead) yapar** ve canlıda tamamen geçersizdir.

Tablo 2: Mevcut Araştırma Hattına Eklenecek 6 ML Kullanım Alanının Karşılaştırması

Kullanım Alanı	Yöntem ve Algoritma	Kanıt Düzeyi	Temel Riskler	Uygulama Zorluğu (GitHub Actions CPU)	Beklenen Net Katkı
1. Meta-Labeling (Sinyal Filtreleme)	Birincil Pine stratejisi yönü (`+1`/`-1`) verir; LightGBM / Lojistik Regresyon üçlü bariyer (triple-barrier) başarı olasılığını tahmin eder	**[Yüksek - Hakemli & Kurumsal]** (López de Prado, 2018)	Strateji başına az işlem varsa aşırı uyum (Havuzlanmış/Pooled eğitimle çözülür)	**Düşük–Orta** (CPU'da <5 sn eğitim, mevcut Pine sinyallerinin üstüne biner)	**Çok Yüksek:** Yanlış pozitifleri ve komisyon erimesini %30–50 azaltır, Sharpe'ı artırır
2. Rejim Tespiti (Strateji Aç/Kapa)	`hmmlearn` (GaussianHMM 2–3 durumlu) veya GARCH/Gerçekleşen Volatilite + ADX/Korelasyon kümelemesi	**[Yüksek - Hakemli]** (PickMyTrade, 2026)	Tüm örneklem (full-sample) üzerinde HMM eğitilirse ileriye dönük sızıntı oluşur (Genişleyen pencere şart)	**Düşük** (Çok hızlı, az parametreli, yüksek yorumlanabilirlik)	**Yüksek:** Kriz ve yatay testere (whipsaw) dönemlerinde %10 zarar bütçesini korur
3. Portföy Ağırlıkları (HRP / HERC / NCO)	`skfolio` ile tek kapıyı geçen stratejileri 20 kümeye ayırma ve Hiyerarşik Risk Paritesi / CVaR ile ağırlıklandırma	**[Çok Yüksek - Hakemli]** (López de Prado, 2016; skfolio, 2026)	Çok kısa geçmişli stratejilerde korelasyon matrisi gürültüsü (Ledoit-Wolf büzülmesi / shrinkage ile çözülür)	**Çok Düşük** (`scikit-learn` uyumlu `skfolio` ile 20 satır kod, <1 sn çalışma)	**Çok Yüksek:** 20 gölge kitabın aynı gizli faktöre yığılmasını önler, OOS varyansı düşürür
4. Volatilite ve Kuyruk Riski Tahmini	HAR-RV (günlük/haftalık/aylık RV) + Yang-Zhang Volatilite + LightGBM Quantile Regression (α = 0.05)	**[Çok Yüksek - Hakemli]** (Corsi, 2009; Noguer i Alonso, 2026)	Ani likidite şoklarında gecikme (Kısa vadeli Yang-Zhang / emir akışı dengesizliği ile desteklenmeli)	**Düşük** (Doğrudan mevcut "%10 oynaklık ölçekleme" modülünün içine yerleşir)	**Yüksek:** Sabit pencere std yerine dinamik $\hat{\sigma}_{t+1}$ ile daha pürüzsüz sermaye eğrisi

Kullanım Alanı	Yöntem ve Algoritma	Kanıt Düzeyi	Temel Riskler	Uygulama Zorluğu (GitHub Actions CPU)	Beklenen Net Katkı
5. Copy Trading Lider Seçimi (Faz 2)	Hyperliquid/MQL5 liderlerinin geçmiş metriklerinden (Disposition etkisi, Equity/Balance DD, kaldıraç) gelecek 30g Calmar tahmini	**[Orta–Yüksek - Hakemli]** (Pelster & Hofmann, 2018)	CEX'lerde kapanan liderlerin verisinin silinmesi (Yalnızca Hyperliquid veya ileriye dönük kaydedilen veriyle çalışır)	**Orta** (En az 3–6 aylık lider panel verisi biriktirmeyi gerektirir)	**Orta–Yüksek:** Zirvede kopyalanıp ortalamaya dönen (batacak) liderleri eler
6. TradingView "ML" Göstergeleri (`jdehorty` vb.)	Pine Script içinde modülo-4 taramalı yaklaşık KNN (Lorentzian uzaklık) + Nadaraya-Watson çekirdek filtresi	**[Düşük - Perakende Betik]** (Gist Kodu)	`y_train` tanımında geçmiş momentumun etiket sanılması; LuxAlgo benzeri türevlerde ağır repainting	**Mevcut** (942 strateji içinde sıradan bir teknik strateji adayı olarak test edilebilir)	**Düşük:** Gerçek bir ML katmanı değildir; yalnızca tek kapıdan geçerse sıradan bir sinyal olarak tutulabilir

4. Doğrulama Metodolojisi: Veri Sızıntısı, Çoklu Test Düzeltmesi ve Model Kayması

Finansal zaman serilerinde standart `scikit-learn` `train_test_split(shuffle=True)` veya standart `KFold` kullanmak, otokorelasyon ve örtüşen etiket pencereleri nedeniyle **%100 veri sızıntısına (data leakage)** yol açar (Quant67 Backtest Pitfalls, Mayıs 2026).

4.1. Veri Sızıntısı Türleri ve Önlenmesi: Purged K-Fold, Embargo ve CPCV

1. **Örtüşen Etiketler (Overlapping Labels) ve Purging (Temizleme):** Bir strateji t_i anında işlem açıp $t_i + h$ anında kapattığında, bu işlemin etiketi $[t_i, t_i + h]$ aralığındaki fiyat yoluna bağlıdır. Eğer eğitim kümesindeki bir örnek $[t_j, t_j + h]$ ile test kümesindeki $[t_i, t_i + h]$ zaman olarak kesişiyorsa, test verisi eğitim kümesine sızmış demektir. **Purging**, test penceresiyle zaman olarak örtüşen tüm eğitim örneklerinin eğitim kümesinden silinmesidir (skfolio / mlfinpy Docs, 2026).
2. **Seri Korelasyon ve Embargo (Ambargo):** Finansal öznitelikler (ör. 20 barlık RSI, volatilite, emir akışı) uzun hafızaya sahiptir. Test kümesinin hemen ardından gelen eğitim örnekleri, test kümesinin sonundaki şokların izini taşır. **Embargo**, her test bloğunun hemen sonrasındaki δ kadar sürenin (örneğin maksimum tutma süresinin %1–%2'si veya en uzun öznitelik penceresi kadar barın) eğitim kümesinden çıkarılmasıdır.
3. **Combinatorial Purged Cross-Validation (CPCV) vs. Walk-Forward:**
4. **Walk-Forward (İleriye Yürüyen Doğrulama):** Tarihsel olarak gerçekçidir ancak yalnızca **tek bir tarihsel yol (single path)** test eder; bu tek yola aşırı uyum sağlama riski yüksektir ve verinin ilk kısmını hiç test etmez.
5. **CPCV (`skfolio.model_selection.CombinatorialPurgedCV`):** Zaman serisini N bloğa (ör. N = 6) böler ve her seferinde k bloğu (ör. k = 2) test kümesi olarak seçerek C(N, k) = 15 farklı kombinasyonda purging ve embargo uygular. Bu 15 kombinasyon birleştirildiğinde **φ = 5 adet tam uzunlukta bağımsız örneklem dışı backtest yolu (backtest paths)** elde edilir ve aşırı uyum olasılığı (PBO) doğrudan ölçülebilir (ResearchGate PBO, Ağustos 2026).

4.2. Çoklu Test ve Aşırı Uyum Düzeltmesi: "942 Strateji + Sıralama" Yapımıza Hangisi Uyar?

Sisteminizde **~942 stratejiyi** test edip en iyilerini seçtiğiniz için ciddi bir **Çoklu Test (Multiple Testing / Selection Bias)** problemi mevcuttur: Tamamen rastgele gürültü üreten 942 stratejiyi test etseniz bile, normal

dağılım altında beklenen en yüksek örneklem içi Sharpe oranı Euler-Mascheroni sabiti ($\gamma \approx 0.5772$) ile şu değere şişer:

$$\mathbf{E[\max_{1\le n\le N} SR_n] \approx \sqrt{V[\{SR_n\}]} \cdot [\,(1-\gamma)\Phi^{-1}(1-1/N) + \gamma\Phi^{-1}(1-1/(N\cdot e))\,]}$$

$N = 942$ için $\Phi^{-1}(1 - 1/942) \approx 3.07$ olduğundan, **gerçek Sharpe oranı 0 olan 942 rastgele stratejinin içinden en iyisi seçildiğinde, yalnızca şans eseri ≈ 3.25 × σ_{SR} büyüklüğünde sahte bir Sharpe oranı görülür!** (Bailey ve López de Prado, 2014 - *Deflated Sharpe Ratio*; Quant67, Mayıs 2026).

Dört temel istatistiksel düzeltme aracının karşılaştırması ve **sizin sisteminize tam uyan mimari**:

1. **Deflated Sharpe Ratio (DSR - Bailey ve López de Prado, 2014):** Seçilen stratejinin Sharpe oranının (SR), denenen toplam bağımsız strateji sayısı (N_{eff}), örneklem uzunluğu (T), getirilerin çarpıklığı ($\hat{\gamma}_3$ - skewness) ve basıklığı ($\hat{\gamma}_4$ - kurtosis) düzeltildikten sonra beklenen maksimum sahte Sharpe'ı (SR_0) aşma olasılığıdır:

$$\mathbf{DSR = \Phi(\,[\,(SR - SR_0)\cdot\sqrt{(T-1)}\,] \,/\, \sqrt{[\,1 - \gamma_3\cdot SR + ((\gamma_4 - 1)/4)\cdot SR^2\,]}\,)}$$

2. **Bizim sisteme uyumu:** Çok yüksektir; ancak 942 stratejinin tamamı birbirinden bağımsız olmadığı için N = 942 yazmak aşırı cezalandırır. Bunun yerine strateji korelasyon matrisinden hesaplanan **Efektif Bağımsız Deneme Sayısı (N_{eff})** kullanılmalıdır.

3. **Probability of Backtest Overfitting (PBO - Bailey, Borwein, López de Prado ve Zhu, 2017):** CPCV matrisinin örneklem içi (IS) en iyi stratejisinin, örneklem dışı (OOS) sıralamada medyanın altında kalma olasılığıdır (PBO < 0.05 hedeflenir) (ResearchGate, Ağustos 2026).
4. **Bizim sisteme uyumu:** Yazarın sabit ayarlarıyla tek bir "yayın sonrası" pencerede koşan 942 strateji için değil, **üst katmanda eğittiğimiz ML modellerinin (Meta-labeling / Rejim hiperparametrelerinin) aşırı uyumunu test etmek için** idealdir.
5. **White's Reality Check (2000) & Hansen's SPA (Superior Predictive Ability, 2005):** En iyi stratejinin sıfır getiri (benchmark) karşısındaki üstünlüğünü, **942 strateji arasındaki çapraz korelasyonları ve zaman serisi bağımlılığını Politis-Romano durağan blok bootstrap (stationary block bootstrap) ile tam olarak koruyarak** test eder (Kevin Sheppard `arch.bootstrap.SPA` Docs, 2026). Hansen'in SPA testi, aşırı kötü performans gösteren stratejilerin test gücünü düşürmesini öğrenci-tipi (studentized) yeniden merkezleme ile engeller.
6. **Romano-Wolf StepM (Stepwise Multiple Testing) & Benjamini-Hochberg / Storey FDR (False Discovery Rate):** Hansen SPA yalnızca *"942 strateji içinde en az 1 tane gerçek strateji var mı?"* sorusunu yanıtlarken, **Romano-Wolf `StepM`** (`arch.bootstrap.StepM`) ve **False Discovery Rate (FDR)** *"Hangi spesifik stratejiler (20 gölge kitap adayları) gerçek alfaya sahiptir?"* sorusunu yanıtlar (arch.bootstrap Docs, 2026).

Sizin "942 Strateji + Blok Bootstrap p10 + 20 Gölge Kitap" Yapınıza Tam Uyan 3 Adımlı Protokol: * **Adım 1 (Bireysel Kapı - DSR):** Yayın sonrası sınama döneminde net > 0 olan stratejiler için efektif bağımsız strateji sayısı $N_{eff} = (\Sigma\lambda_i)^2 / \Sigma\lambda_i^2$ (veya korelasyon küme sayısı) kullanılarak **DSR > 0.90** hesaplanır. * **Adım 2 (Aile Boyu ve Çoklu Seçim Kapısı - `arch.bootstrap.StepM` + BH-FDR):** Tek kapıyı geçen adayların yayın sonrası günlük net getiri matrisi (T × M), Python `arch` kütüphanesindeki **`StepM(benchmark=0, reps=1000, block_size=sqrt(T))`** (Romano-Wolf basamaklı blok bootstrap) veya blok-bootstrap p-değerleri üzerinden **Benjamini-Hochberg FDR (q ≤ 0.10)** süzgecinden geçirilir. Mevcut "blok bootstrap p10" sıralamanız korunduğu için bu adım mevcut mimarinize всего 15 satır kodla eklenir. * **Adım 3 (ML Katmanı Doğrulaması - CPCV & PBO):** Seçilen stratejilerin üzerine eğitilen Meta-Labeling modeli `skfolio` `CombinatorialPurgedCV` ile doğrulanır ve PBO < 0.10 şartı aranır.

4.3. Etiketleme (Triple-Barrier, Trend-Scanning) ve Özellik Önemi (MDI, MDA, SFI, SHAP)

- **Etiketleme:** Sabit zaman ufuklu etiketleme ($r_{t,t+h} > 0$), bar içi volatiliteyi ve stop-loss/take-profit dinamiklerini yok sayar. Bunun yerine **Üçlü Bariyer Yöntemi (Triple-Barrier Method)** kullanılmalıdır: Üst bariyer (dinamik günlük/saatlik volatilitenin pt_{mult} katı kâr al), alt bariyer (sl_{mult} katı zarar kes) ve dikey

bariyer (h bar zaman aşımı) (iotdigitaltwinplm, 9 Ekim 2026). Trend takip stratejileri için alternatif olarak ileriye dönük farklı pencerelerdeki doğrusal regresyon t-istatistiğini maksimize eden **Trend-Scanning Labeling** (MQL5 Blueprint, Ekim 2025) kullanılabilir.

- **Özellik Önemi ve Kararsızlık:**
- **MDI (Mean Decrease Impurity):** Ağaç içi bölünme kazancına bakar; yalnızca örneklem içi (in-sample) çalışır ve sürekli/yüksek kardinaliteli değişkenleri yapay olarak öne çıkarır.
- **MDA (Mean Decrease Accuracy / Permutation Importance) & SHAP:** Purged K-Fold örneklem dışı (OOS) katmanlarında özelliğin karıştırılmasıyla (permutation) ölçülür. Ancak birbirine yüksek korelasyonlu iki özellik varsa (ör. `RSI_14` ve `RSI_20`), ikame etkisi (substitution effect) nedeniyle ikisinin de önemi yarıya düşer.
- **Çözüm (Kümelenmiş MDA / Clustered MDA & SFI):** Öznitelikler önce hiyerarşik olarak kümelenmeli ve permütasyon **küme bazında** yapılmalı veya tekil özellik performansı için **SFI (Single Feature Importance)** ile çapraz kontrol edilmelidir. Farklı CV katmanları (folds) arasında özellik önem sıralaması sürekli değişiyorsa (düşük Kendall τ korelasyonu), o özellik gürültüdür ve elenmelidir.

4.4. Canlı İzleme (Paper Trading), Model Kayması (Drift) Tespiti ve Yeniden Eğitim Sıklığı

20 gölge kitapta (paper trading) çalışan bir ML katmanı (örneğin Meta-Labeling modeli), piyasa mikro-yapısı değiştikçe iki tür bozulmaya uğrar: 1. **Öznitelik Kayması (Covariate Shift - P(X) değişimi):** Giriş özelliklerinin veya tahmin edilen olasılıkların dağılımının eğitim dağılımından uzaklaşması. **Popülasyon Kararlılık Endeksi (PSI - Population Stability Index)** ile izlenir:

$$\mathrm{PSI} = \Sigma_{b=1..B} \left(p_{b,\text{canlı}} - p_{b,\text{eğitim}}\right) \cdot \ln\left(p_{b,\text{canlı}} / p_{b,\text{eğitim}}\right)$$

PSI < 0.10 ise dağılım kararlıdır; PSI ∈ [0.10, 0.25] ise uyarı verilir; **PSI > 0.25 ise model dağılım dışına (out-of-distribution) çıkmıştır ve yeniden eğitim tetiklenir**. 2. **Kavram Kayması (Concept Drift - P(Y|X) değişimi):** Özellikler aynı kalsa bile piyasanın tepkisinin değişmesi. Meta-modelin canlıdaki **yuvarlanan Brier Skoru** ($BS = (1/N)\Sigma(P_i - y_i)^2$) ve gerçekleşen kümülatif net PnL üzerinde **Page-Hinkley / CUSUM** testi ile izlenir. Eğer meta-etiketli portföyün yuvarlanan 30 işlemlik Brier skoru baz çizgisini (hiç filtrelememe durumunu) geçemiyorsa, meta-model otomatik olarak devre dışı bırakılır (fallback: birincil stratejinin ham sinyaline veya nakde dönüş). 3. **Yeniden Eğitim Sıklığı (Retraining Cadence):** Her gün model eğitmek (daily retraining) işlem maliyetini ve model varyansını artırır. Kripto/Forex saatlik-4 saatlik stratejilerde **ayda 1 kez (veya PSI > 0.25 olduğunda)**, günlük hisse/BIST stratejilerinde **çeyrekte 1 kez** genişleyen/kayan pencere (expanding/rolling window) ile yeniden eğitim en kararlı sonucu verir.

5. Pratik Araç Seti: Açık Kaynak Python Kütüphaneleri, GitHub Actions CPU Uyumu ve Ücretsiz Veri

5.1. Kütüphanelerin 2026 Lisans, Bakım ve Olgunluk Durumu

- **`mlfinlab` (Hudson & Thames) Lisans Uyarısı:** Eskiden açık kaynak olan `mlfinlab`, tamamen ticari/ücretli kapalı abonelik modeline geçmiştir; eski açık kaynak sürümleri ise güncel `pandas >= 2.0` ve `numpy >= 2.0` ile kırılmaktadır (PickMyTrade Guide, 2026). **Kullanılmamalıdır.**
- **`mlfinlab`'in Ücretsiz ve Aktif Açık Kaynak Alternatifleri (2026):**
- **`skfolio` (BSD-3-Clause Lisansı, Aktif 2026):** `scikit-learn` API standardında inşa edilmiş en modern portföy ve çapraz doğrulama kütüphanesidir (skfolio Docs; awesome-quant GitHub, Mayıs 2026). İçinde **CombinatorialPurgedCV**, **HRP**, **HERC**, **NCO**, CVaR optimizasyonu ve kovaryans büzülme (shrinkage) modülleri yerleşik, hızlı ve tam testlidir.
- **`Riskfolio-Lib` (BSD-3-Clause, C++ hızlandırmalı, Aktif Mayıs 2026):** Daniel Cajas tarafından geliştirilen, HRP/HERC/NCO ve 24 farklı risk ölçütünü destekleyen çok olgun bir kütüphanedir (awesome-quant, Mayıs

2026).

- **`mlfinpy` / Yerel Numba Fonksiyonları:** Triple-barrier etiketleme, meta-labeling, kesirli fark alma (fractional differentiation - `fracdiff`) ve örneklem benzersizliği (sample uniqueness) ağırlıkları için `mlfinpy` (mlfinpy Docs) veya 80 satırlık saf numpy/numba kodu sıfır bağımlılık riskiyle çalışır.

Tablo 3: Açık Kaynak Python Finansal ML Kütüphaneleri Karşılaştırması (Ekim 2026)

Kütüphane	Lisans ve Maliyet	Ekim 2026 Bakım ve Olgunluk Durumu	Güçlü Yönleri ve Temel İşlevi	GitHub Actions (2-vCPU, 7GB RAM, GPU Yok) Uyumu	Bizim Sistemdeki Rolü
`LightGBM` / `XGBoost` / `CatBoost` (Kaynak, 2026)	MIT / Apache-2.0 (**Ücretsiz**)	**Çok Olgun ve Aktif** (`lightgbm-org/LightGBM` Mart 2026'da bağımsız organizasyona taşındı)	Tablosal finansal veride en yüksek OOS başarısı, örneklem ağırlıklandırma (`sample_weight`), eksik veri yönetimi	**Mükemmel:** CPU'da çok iş parçacıklı (multi-threaded) saniyeler içinde eğitilir	**Ana ML Motoru** (Meta-labeling, rejim ve lider seçimi)
`skfolio` (Kaynak, Mayıs 2026)	BSD-3-Clause (**Ücretsiz**)	**Çok Aktif (Mayıs 2026 güncellemeli)**, modern `scikit-learn >= 1.4` mimarisi	**CPCV (`Combinatorial PurgedCV`)**, Purged K-Fold, **HRP, HERC, NCO**, CVaR ve entropi havuzlama	**Mükemmel:** Saf CPU / NumPy / SciPy / Clarabel tabanlı, çok hafif	**Doğrulama (CPCV) ve 20 Gölge Kitap Ağırlıklandırma (HRP/NCO)**
`arch` (Kevin Sheppard) (Kaynak, 2026)	NCSA / BSD (**Ücretsiz**)	**Endüstri Standardı (`v7.2.0`)**, akademik olarak en güvenilir ekonometri paketi	**White's Reality Check, Hansen SPA, Romano-Wolf `StepM`**, Durağan Blok Bootstrap, GARCH modelleri	**Mükemmel:** Cython/Numba hızlandırmalı, 942 strateji bootstrap testi ~3–8 sn sürer	**Çoklu Test (SPA / StepM) ve Volatilite Modelleme**
`Riskfolio-Lib` & `PyPortfolioOpt` (Kaynak, Temmuz 2026)	BSD-3 / MIT (**Ücretsiz**)	İkisi de aktif (`PyPortfolioOpt` Temmuz 2026, `Riskfolio-Lib` Mayıs 2026)	Klasik Etkin Sınır, Black-Litterman, HRP, HERC, Kuyruk Riski (CDaR, EVaR) optimizasyonu	**Mükemmel:** Hafif CPU çözücüleri (`cvxpy` / `ecos` / `clarabel`)	`skfolio` yanında yardımcı portföy/kümeleme aracı
`hmmlearn` & `ruptures` (Kaynak, 2026)	BSD (**Ücretsiz**)	Olgun ve kararlı (`scikit-learn` tarzı API)	`hmmlearn`: Gaussian/GMM Gizli Markov rejim tespiti; `ruptures`: yapısal kırılma analizi	**Mükemmel:** Milisaniyeler içinde CPU'da çalışır	**Rejim Tespiti Katmanı**
`vectorbt` (Open Source vs. PRO)	Açık sürüm: Apache-2.0; PRO: Ücretli	Açık kaynak sürümü (`v0.26.x`) dondurulmuş/yavaş; yeni özellikler ücretli `vectorbtpro`'da	Numba ile hızlandırılmış vektörel backtest ve parametre taraması	**Çok İyi** (Numba JIT derlemesi CPU'da çok hızlıdır); ancak `pandas 2.x` uyumluluk yamalarına dikkat edilmeli	Mevcut Pine yorumlayıcınız zaten var; hızlı vektörel prototipleme dışında zorunlu değil

Kütüphane	Lisans ve Maliyet	Ekim 2026 Bakım ve Olgunluk Durumu	Güçlü Yönleri ve Temel İşlevi	GitHub Actions (2-vCPU, 7GB RAM, GPU Yok) Uyumu	Bizim Sistemdeki Rolü
`Microsoft Qlib` (Kaynak, 2026)	MIT (**Ücretsiz**)	Aktif (`v0.9.7`, RD-Agent entegrasyonlu), ancak ağır ve karmaşık	Uçtan uca kesitsel (cross-sectional) hisse senedi alfa madenciliği ve özel ikili (binary) veri formatı	**Zayıf–Orta:** Kendi ağır veri tabanı yapısını dayatır; mevcut 942 Pine strateji hattınıza entegre etmek aşırı mühendislik yükü yaratır	**Önerilmez** (Mevcut modüler Python hattınızı bozar)
`FinRL` (Kaynak, 2026)	MIT (**Ücretsiz**)	Aktif (`FinRL-X` ve yarışmalar), ancak akademik/eğitsel odaklı	Pekiştirmeli öğrenme (PPO, SAC, A2C) ortamları	**Zayıf:** PyTorch/Gymnasium eğitimi CPU'da yavaştır ve canlıda "Reality Gap" sorunu vardır	**Önerilmez**
`Darts` / `sktime` / `statsforecast` (Nixtla)	Apache-2.0 / BSD (**Ücretsiz**)	Çok aktif; özellikle Nixtla `statsforecast` ve `mlforecast` Numba tabanlı ve çok hızlı	Birleşik zaman serisi tahmin arayüzü, ARIMA/ETS/HAR/LightGBM sarmalayıcıları	`statsforecast` / `mlforecast` CPU'da mükemmel; `Darts` (PyTorch kısmı) GitHub Actions için ağır	Volatilite tahmini için `statsforecast` veya doğrudan `scikit-learn`/`LightGBM` yeterli

5.2. GitHub Actions (Sınırlı CPU) Ortamında Eğitilebilirlik ve Ücretsiz Özellik Kaynakları

GitHub Actions standart ücretsiz/standart koşucuları (2–4 vCPU, 7–16 GB RAM, GPU yok, iş başına süre sınırı) derin öğrenme veya RL modelleri için dar boğaz yaratırken, **LightGBM + `skfolio` + `arch` + `hmmlearn`** yığını için fazlasıyla yeterlidir: 942 stratejinin ürettiği ~50.000 tarihsel işlem sinyali üzerinde 25 öznitelikli bir LightGBM Meta-Labeling modelini 15 kombinasyonlu CPCV ile eğitmek **2 vCPU üzerinde yalnızca 4 ila 12 saniye** sürer. Model ağırlıkları `.txt` / `.joblib` olarak yalnızca birkaç yüz kilobayttır ve doğrudan GitHub Actions Artifacts veya repo önbelleğinde (cache) saklanabilir.

Mevcut Ücretsiz Veri Kaynaklarınızdan Çıkarılabilecek Yüksek Sinyalli ML Özellikleri: 1. **Binance (`data.binance.vision` & `/fapi/v1`):** * `aggTrades` / `klines`: **Taker Buy Volume Ratio** (V_{taker_buy} / V_{total} — emir akışı dengesizliği / Order Flow Imbalance), **VPIN (Volume-Synchronized Probability of Informed Trading)** yaklaşımı ve işlem sayısı başına ortalama lot büyüklüğü (balina vs. perakende aktivitesi) (Binance Data Collection, Ekim 2026). * `fundingRate` & `metrics` (Açık Faiz / Open Interest): 8 saatlik fonlama oranının 30 günlük Z-skoru (aşırı kalabalık long/short tespiti) ve fiyat yükselirken Açık Faizin (OI) artıp azalması (yeni para girişi vs. short squeeze) (Binance Vision FundingRate, Ekim 2026). 2. **OHLCV (yfinance, Dukascopy, BIST/VİOP):** * **Kesirli Fark Alınmış Fiyatlar (Fractional Differentiation, d ≈ 0.35 – 0.45):** Fiyat serisini durağanlaştırırken (ADF testini geçirirken) uzun vadeli hafızayı (%80+ korelasyon) silmeyen tek dönüşüm. * **Yang-Zhang ve Garman-Klass Volatilite Tahmincileri:** Sadece kapanış fiyatına bakan standart sapmaya göre açılış sıçramalarını (overnight jumps) ve bar içi yüksek/düşük aralıklarını kullandığı için 7–8 kat daha verimli (efficient) volatilite ölçümü. * **Hurst Üssü (Hurst Exponent) ve Varyans Oranı (Variance Ratio):** Serinin o an ortalamaya dönüş ($H < 0.45$) mü yoksa momentum ($H > 0.55$) rejiminde mi olduğunu ölçen yerel öznitelikler. 3. **Makro ve Kurumsal (yfinance & SEC EDGAR):** * `^VIX` / `^VXN` eğim yapısı, ABD 10Y–2Y tahvil faiz farkı, `DX-Y.NYB` (Dolar Endeksi) 20 günlük momentumu ve SEC EDGAR'dan çekilen 13F kurumsal yoğunlaşma değişimleri.

6. Sonuç: En Yüksek Değer/Maliyet Oranlı 3 ML Pilotu, Kırmızı Bayraklar ve Okuma Listesi

6.1. Bizim Sisteme Eklenecek En Yüksek Değer/Maliyet Oranlı 3 ML Pilotu

Aşağıdaki üç pilot, mevcut **"942 strateji → Yayın sonrası uygulanabilir sınama net > 0 → %10 oynaklık ölçekleme → Blok bootstrap p10 → Kopya ayıklama → 20 gölge kitap (%10 zarar bütçesi)"** hattınızın hiçbir parçasını bozmadan, doğrudan üst katman olarak eklenmek üzere tasarlanmıştır:

Pilot 1: 20 Gölge Kitap Seçimi ve Sermaye Dağıtımı İçin `skfolio` HRP/NCO + `arch` Romano-Wolf StepM Katmanı

- **Hedef:** Tek kapıyı (yayın sonrası net > 0) geçen stratejiler arasındaki çoklu test (data snooping) yanılsamasını istatistiksel olarak elemek ve kalan stratejileri 20 gölge kitaba gizli faktör çakışması olmayacak şekilde dağıtıp ağırlıklandırmak.
- **Veri:** Tek kapıyı geçen stratejilerin yayın sonrası (out-of-sample) günlük gerçekçi maliyet düşülmüş net getiri serileri (T × M matrisi, sıfır dış veri ihtiyacı).
- **Model ve Yöntem:**
- `arch.bootstrap.StepM` (veya Deflated Sharpe Ratio + Benjamini-Hochberg FDR q ≤ 0.10) ile şans eseri net > 0 kalmış stratejilerin elenmesi.
- Kalan stratejilerin korelasyon uzaklık matrisi üzerinde Ward Hiyerarşik Kümeleme ile **20 ayrık küme** oluşturulması ve her kümeden blok bootstrap p10 skoru en yüksek 1 stratejinin 20 gölge kitaba atanması.
- Bu 20 gölge kitabın sermaye ağırlıklarının `skfolio.optimization.HierarchicalRiskParity(risk_measure=RiskMeasure.CVAR)` ile belirlenmesi.
- **Sızıntısız Doğrulama:** Ağırlıklar yalnızca t anına kadarki yayın sonrası geçmiş pencere (expanding/rolling window) üzerinde hesaplanır ve [t+1, t+21] (sonraki 1 ay) boyunca sabit tutularak ileriye dönük yürütülür.
- **Başarı Ölçütü (TEST_YAPISI Uyumlu):** Yayın sonrası dönemde mevcut "eşit ağırlıklı / p10 sıralamalı 20 gölge kitap" baz çizgisine kıyasla; (a) Портföy Maksimum Drawdown (MDD) ve %95 CVaR değerinde **en az %15 iyileşme (%10 zarar bütçesi aşımının sıfırlanması)** ve (b) Maliyet sonrası net Calmar ve Deflated Sharpe oranında artış.
- **Tahmini Emek: 2–3 Gün** (~150 satır Python kodu, GitHub Actions'ta ek çalışma süresi <10 saniye).

Pilot 2: Birincil Strateji Sinyallerinin Üstüne Havuzlanmış (Pooled) LightGBM Meta-Labeling ve Dinamik Rejim Filtresi

- **Hedef:** 20 gölge kitaba giren (veya tek kapıyı geçen) TradingView stratejilerinin ters piyasa rejimlerinde ürettiği yanlış pozitif (false positive) sinyalleri süzerek işlem maliyetlerini düşürmek ve sinyal kalitesini artırmak.
- **Veri:** Birincil stratejinin sinyal anındaki (t_i) özellikleri: (a) Rejim özellikleri (`hmmlearn` 2-durumlu volatilite olasılığı, 20/60 barlık Yang-Zhang volatilite oranı, Hurst üssü, ADX), (b) Stratejinin kendi son 10 işlemdeki yuvarlanan kazanma oranı ve özsermaye eğrisi eğimi, (c) Kripto için Binance Taker Buy Oranı ve Funding Rate Z-skoru.
- **Model ve Yöntem:** Birincil sinyaller **Üçlü Bariyer (Triple-Barrier)** yöntemiyle (maliyet sonrası net kâr > 0 ise `1`, zarar/stop ise `0`) etiketlenir. Çok sığ bir **`LightGBMClassifier(max_depth=3, num_leaves=7, min_child_samples=50, learning_rate=0.03)`** ve karşılaştırma için **`LogisticRegression(penalty='l2')`** eğitilir. Modelin ürettiği olasılık P(y=1) < 0.52 ise sinyal veto edilir; P ≥ 0.52 ise pozisyon boyutu olasılıkla ölçeklenir.
- **Sızıntısız Doğrulama:** `skfolio.model_selection.CombinatorialPurgedCV(n_splits=6, n_test_splits=2, purge_threshold=max_holding_bars, embargo_threshold=20)` ile doğrulanır;

yalnızca stratejinin yayın sonrası (veya eğitim kesim sonrası) ileriye yürüyen (walk-forward) döneminde değerlendirilir.

- **Başarı Ölçütü (TEST_YAPISI Uyumlu):** Eğitim sonrası test döneminde ham birincil stratejiye kıyasla; (a) Toplam işlem sayısında ve ödenen komisyon/kaymada %25–%40 azalma, (b) Precision ve F1 skorunda artış, (c) Maliyet sonrası net getiri / MDD (Calmar) oranında en az **%20 iyileşme** ve CPCV **PBO < 0.15**.
- **Tahmini Emek: 5–7 Gün** (~350 satır Python kodu, GitHub Actions'ta çalışma süresi ~15–30 saniye).

Pilot 3: "%10 Oynaklık Ölçekleme" Katmanı İçin HAR-RV + Yang-Zhang + LightGBM Kuantil Volatilite Tahmincisi

- **Hedef:** Mevcut sisteminizdeki "%10 oynaklık ölçekleme" (volatility targeting) adımında kullanılan geriye dönük basit standart sapmanın şoklara geç tepki verme sorununu çözerek, gerçekleşen portföy volatilitesini %10 hedefine sabitlemek ve ani çöküşlerde pozisyon boyutunu şok büyümeden küçültmek.
- **Veri:** Günlük/saatlik OHLCV verisinden hesaplanan Yang-Zhang volatilitesi, 1-günlük ($RV^{(d)}$), 5-günlük ($RV^{(w)}$) ve 22-günlük ($RV^{(m)}$) gerçekleşen volatilite serileri, hacim şokları ve (varsa) VIX / Funding Rate mutlak değeri.
- **Model ve Yöntem: Ridge-düzenlileştirmeli HAR-RV** temel modeli ve **LightGBM Quantile Regressor (α = 0.50 medyan volatilite ve α = 0.90 üst kuyruk volatilitesi)** ile bir sonraki dönemin volatilitesi ($\hat{\sigma}_{t+1}$) tahmin edilir. Pozisyon boyutu min(0.10 / $\hat{\sigma}_{t+1}^{(0.50)}$, 0.15 / $\hat{\sigma}_{t+1}^{(0.90)}$) formülüyle belirlenir.
- **Sızıntısız Doğrulama:** Genişleyen pencere (expanding window) walk-forward; hiçbir zaman gelecek barın yüksek/düşük verisi bugünkü ölçeklemeye sızdırılmaz (kesin t−1 gecikmeli).
- **Başarı Ölçütü (TEST_YAPISI Uyumlu):** Mevcut standart oynaklık ölçeklemeye kıyasla; (a) Örneklem dışı gerçekleşen yıllık volatilitenin %10 hedefine olan ortalama karesel hatasında (MSE / QLIKE kaybında) **en az %20 düşüş**, (b) En kötü %5'lik günlerdeki kayıpta (Expected Shortfall / CVaR) azalma.
- **Tahmini Emek: 2–3 Gün** (~120 satır Python kodu, GitHub Actions'ta çalışma süresi <5 saniye).

Tablo 4: Önerilen 3 ML Pilotunun Uygulama ve Doğrulama Yol Haritası

Pilot	Hedeflenen Sistem Katmanı	Girdi Verisi ve Özellikler	Model ve Kütüphane	Sızıntısız Doğrulama	Başarı Ölçütü (Maliyet & Eğitim Sonrası)	Tahmini Emek
Pilot 1: Çoklu Test Elemesi + HRP/NCO 20 Kitap Dağıtımı	Tek Kapı Sonrası Sıralama → 20 Gölge Kitap Seçimi & Ağırlıklandırma	Aday stratejilerin yayın sonrası günlük net getiri matrisi (T × M)	`arch.bootstrap.StepM` + Ward Kümeleme (20 küme) + `skfolio HierarchicalRiskParity`	Yalnızca geçmiş yayın sonrası pencerede aylık yuvarlanan ağırlıklandırma	20 Gölge Kitap MDD ve CVaR'da ≥ %15 düşüş; DSR > 0.90; %10 zarar bütçesi korunumu	**2–3 Gün**
Pilot 2: Havuzlanmış Meta-Labeling & Rejim Filtresi	Birincil TradingView Sinyalleri → Emir Boyutu / Veto Kararı	Yang-Zhang vol, `hmmlearn` rejim olasılığı, Hurst, ADX, strateji son 10 işlem PnL, Binance Taker/Funding	`LightGBMClassifier(max_depth=3)` + `LogisticRegression` baz çizgisi (Triple-Barrier etiketli)	`skfolio CombinatorialPurgedCV` (Purge = maks. tutma süresi, Embargo = 20 bar)	İşlem ve komisyon sayısında %25–40 düşüş; net Calmar oranında ≥ %20 artış; PBO < 0.15	**5–7 Gün**

Pilot	Hedeflenen Sistem Katmanı	Girdi Verisi ve Özellikler	Model ve Kütüphane	Sızıntısız Doğrulama	Başarı Ölçütü (Maliyet & Eğitim Sonrası)	Tahmini Emek
Pilot 3: HAR-RV + Quantile Volatilite Ölçekleme	"%10 Oynaklık Ölçekleme" (Volatility Targeting) Modülü	$RV^{(1d)}$, $RV^{(5d)}$, $RV^{(22d)}$, Yang-Zhang vol, hacim Z-skoru	`Ridge` (HAR-RV) + `LGBMRegressor(objective='quantile')`	Genişleyen pencere (Expanding Window) Walk-Forward	Gerçekleşen volatilitenin %10 hedefine QLIKE/MSE hatasında ≥ %20 azalma; sol kuyruk daralması	**2–3 Gün**

6.2. Kesinlikle Kaçınılması Gerekenler ve Kırmızı Bayraklar (Red Flags)

1. **%70–%95 Yön Doğruluğu veya Sharpe > 3.5 İddia Eden Makale ve Betikler:** Likit finansal piyasalarda günlük/saatlik ufukta gerçek örneklem dışı yön doğruluğu %51–%54 bandındadır (Rahimikia ve ark., Mart 2026). %70+ doğruluk raporlayan her çalışmada istisnasız olarak ya hedef değişken öznitelikliere sızmıştır (ör. `y_train` içine bugünün kapanışının girmesi), ya tüm veri seti bölünmeden önce `StandardScaler`/`MinMaxScaler` ile ölçeklenmiştir, ya da merkezlenmiş (centered) filtre/çekirdek (kernel) ile gelecek barlar okunmuştur.
2. **Zaman Serisinde Rastgele `train_test_split` veya Standart `KFold` Kullanımı:** Örtüşen işlem pencerelerini (overlapping labels) temizlemeden (purging) yapılan çapraz doğrulama, eğitim ve test kümelerine aynı fiyat hareketini kopyalar ve sahte bir doğruluk üretir.
3. **Ham (Durağan Olmayan) Fiyat Serilerini Ağaç veya Sinir Ağlarına Beslemek:** Ham kapanış fiyatı (P_t) veya kümülatif OBV gibi durağan olmayan serilerle eğitilen ağaç modelleri, fiyat eğitim dönemindeki maksimum seviyeyi aştığında tamamen işlevsiz kalır (ağaçlar eğitim aralığının dışına ekstrapolasyon yapamaz). Tüm girdiler getiri, Z-skoru, volatilite oranı veya kesirli fark ($d \approx 0.4$) ile durağanlaştırılmalıdır.
4. **TradingView'daki "Non-Repainting" İddialı Çoklu Zaman Dilimi (`request.security`) ve Kernel Betikleri:** Pine Script'te `request.security(syminfo.tickerid, "D", close)` çağrısında `lookahead=barmerge.lookahead_on` kullanılması veya `close[1]` yerine `close` çekilmesi, gün içi barlara o günün akşam kapanış fiyatını sızdırır. Kendi Pine yorumlayıcınızda tüm üst zaman dilimi çağrılarının yalnızca **kapanmış üst barı (`[1]`)** okuduğundan emin olunmalıdır.
5. **LLM'leri Eğitim Kesim Tarihinden (Knowledge Cutoff) Önceki Veride Backtest Etmek:** 2024–2026 model ağırlıklarına sahip bir LLM'i 2020–2024 verisinde test etmek, sınav sorularını önceden ezberlemiş bir öğrenciyi sınava sokmakla aynıdır (arXiv LLM Survey, Mart 2026).

6.3. En Önemli 10 Kaynak (Kitap, Hakemli Makale ve Açık Kaynak Repo) — Okuma Listesi

1. **Marcos López de Prado (2018), *Advances in Financial Machine Learning* (Wiley) [Kitap]:** Triple-barrier etiketleme, **Meta-Labeling**, kesirli fark alma (fractional differentiation), Purged K-Fold, **CPCV**, özellik önemi (MDI/MDA/SFI) ve Deflated Sharpe Ratio kavramlarını finans dünyasına kazandıran temel başucu kitabıdır (Hudson & Thames Özeti).
2. **Shihao Gu, Bryan Kelly ve Dacheng Xiu (2020), *"Empirical Asset Pricing via Machine Learning"*, The Review of Financial Studies, 33(5), 2223–2273 [Hakemli Makale]:** Finansal getirilerde hangi ML modellerinin (GBDT ve sığ NN) neden çalıştığını ve gerçekçi örneklem dışı R^2 sınırının (%0.4) ne olduğunu kanıtlayan en önemli akademik makaledir (Tam Metin PDF).
3. **David H. Bailey ve Marcos López de Prado (2014), *"The Deflated Sharpe Ratio: Correcting for Selection Bias, Backtest Overfitting, and Non-Normality"*, Journal of Portfolio Management [Hakemli Makale]:** 942 strateji gibi çoklu deneme yapılan sistemlerde şans eseri oluşan sahte Sharpe oranlarını matematiksel olarak düzeltmenin standart yöntemidir (ResearchGate Linki).
4. **David H. Bailey, Jonathan Borwein, Marcos López de Prado ve Qiji Jim Zhu (2017), *"The Probability of Backtest Overfitting"*, Journal of Computational Finance [Hakemli Makale]:** Combinatorial Symmetric

Cross-Validation (CSCV/CPCV) ile bir strateji seçim sürecinin aşırı uyum olasılığını (PBO) hesaplayan temel çalışmadır (ResearchGate Linki).

5. **R. David McLean ve Jeffrey Pontiff (2016), *"Does Academic Research Destroy Stock Return Predictability?"*, Journal of Finance, 71(1), 5–32 [Hakemli Makale]:** Sizin sisteminizdeki "yayın sonrası (post-publication) sınama kapısı"nın teorik temelidir; yayınlanan stratejilerin örneklem dışında %26, yayın sonrasında %58 bozulduğunu kanıtlar (RePEc Linki).
6. **Marcos López de Prado (2016), *"Building Diversified Portfolios that Outperform Out-of-Sample"*, Journal of Portfolio Management [Hakemli Makale]:** 20 gölge kitabınızı ağırlıklandıracak olan **Hierarchical Risk Parity (HRP)** algoritmasının orijinal makalesidir; Markowitz'in örneklem dışı kararsızlığını grafik teorisi ve kümeleme ile çözer (ResearchGate Teorik Kanıt, Ağustos 2026).
7. **Peter Reinhard Hansen (2005), *"A Test for Superior Predictive Ability"*, Journal of Business & Economic Statistics & `arch.bootstrap` Dokümantasyonu [Hakemli Makale & Repo]:** Yüzlerce stratejiyi blok bootstrap ile aynı anda sınayan **SPA** ve **Romano-Wolf `StepM`** testlerinin teorisi ve Python uygulamasıdır (`arch.bootstrap.SPA` Docs).
8. **`skfolio` Açık Kaynak Kütüphanesi (`skfolio/skfolio` — GitHub & Dokümantasyon) [Açık Kaynak Repo]:** Ücretli hale gelen `mlfinlab`'in yerini alan, `scikit-learn` tabanlı `CombinatorialPurgedCV`, HRP, HERC ve NCO uygulamalarını ücretsiz (BSD-3) sunan en temiz Python kütüphanesidir (skfolio Docs).
9. **Eghbal Rahimikia ve ark. (Mart 2026), *"Re(Visiting) Time Series Foundation Models in Finance"* & Noguer i Alonso ve Franklin (Haziran 2026, AI Finance Institute) [Akademik Benchmark Makaleleri]:** TimesFM, Chronos ve Moirai gibi yeni nesil foundation modellerinin finansal getiri tahmininde neden GBDT'yi (CatBoost/LightGBM) geçemediğini kanıtlayan güncel 2026 karşılaştırmalarıdır (FoFI Mart 2026 PDF; PickMyTrade 2026 Özeti).
10. **Fulvio Corsi (2009), *"A Simple Approximate Long-Memory Model of Realized Volatility"*, Journal of Financial Econometrics [Hakemli Makale]:** Karmaşık derin öğrenme modellerine gerek kalmadan günlük, haftalık ve aylık gerçekleşen volatiliteyle en güçlü örneklem dışı volatilite tahminini (**HAR-RV**) üreten ve "%10 oynaklık ölçekleme" katmanınızı doğrudan iyileştirecek olan klasik makaledir.

7. Doğrulanmış Kaynak Listesi

1. **Gu, S., Kelly, B., & Xiu, D. (Mayıs 2020):** *Empirical Asset Pricing via Machine Learning*, The Review of Financial Studies, 33(5), 2223–2273 — https://academic.oup.com/rfs/article/33/5/2223/5758276 ve https://dachxiu.chicagobooth.edu/download/ML.pdf
2. **Azevedo, V., Hoegner, C., & Velikov, M. (2023–2025):** *The Expected Returns on Machine-Learning Strategies*, AFA / Journal of Finance — https://afajof.org/management/viewp.php?n=75544
3. **Chen, A. Y., Lopez-Lira, A., & Zimmermann, T. (2025/2026):** *Does Peer-Reviewed Research Help Predict Stock Returns?* (McLean & Pontiff 2016 uzantısı), arXiv:2212.10317v7 — https://arxiv.org/html/2212.10317v7
4. **arXiv (19 Mayıs 2026):** *Machine Learning-Based Bitcoin Trading Under Transaction Costs*, arXiv:2606.00060 — https://arxiv.org/abs/2606.00060
5. **ResearchGate (16 Eylül 2026):** *Research on Machine Learning High-Frequency Trading Strategy of Cryptocurrency Based on Transaction Cost-Aware Filtering* — https://www.researchgate.net/publication/410202442_Research_on_Machine_Learning_High-Frequency_Trading_Strategy_of_Cryptocurrency_Based_on_Transaction_Cost-Aware_Filtering
6. **Rahimikia, E. et al. (Mart 2026):** *Re(Visiting) Time Series Foundation Models in Finance*, FoFI 2026 — http://wp.lancs.ac.uk/fofi2026/files/2026/03/FoFI-2026-020-Eghbal-Rahimikia.pdf
7. **arXiv (23 Mayıs 2026):** *Assessing the Operational Viability of Foundation Models for Time Series (TimesFM 2.5, Chronos vs XGBoost, PatchTST, DLinear)*, arXiv:2605.24381v1 — https://arxiv.org/html/2605.24381v1
8. **PickMyTrade.io (2026):** *Advanced AI Trading Guide: The Complete ML Library, Model & Framework Reference for Quants (2026 Benchmarks & Licensing)* — https://pickmytrade.io/ai-ml/advanced-guide/
9. **arXiv (1 Mart 2026 & 3 Haziran 2025):** *Large Language Model Agent in Financial Trading: A Survey* (arXiv:2408.06361v2) & *TradingAgents: Multi-Agents LLM Financial Trading Framework* (arXiv:2412.20138) — https://arxiv.org/html/2408.06361v2 ve https://arxiv.org/pdf/2412.20138

10. **arXiv (4 Nisan 2026) & MDPI (11 Ekim 2026):** *Realistic Market Impact Modeling for Reinforcement Learning* (arXiv:2603.29086v2) & *Evolution and Challenges of Reinforcement Learning in Intraday Algorithmic Trading* — https://arxiv.org/html/2603.29086v2 ve https://www.mdpi.com/2076-3417/16/20/10060
11. **QuantStrategy.io (6 Ağustos 2026) & Hudson & Thames:** *Meta-Labeling Strategies: Reducing False Positives in Algorithmic Trading – Marcos López de Prado* — https://quantstrategy.io/blog/meta-labeling-strategies-reducing-false-positives-in/ ve https://hudsonthames.org/does-meta-labeling-add-to-signal-efficacy-triple-barrier-method/
12. **jdehorty Lorentzian Classification Pine Script Kaynak Kodu & İncelemesi (Temmuz 2026):** https://gist.github.com/itsXactlY/450618a1ab3a85b450b22c8e188c7a1d ve https://blog.pickmytrade.trade/order-block-ai-pickmytrade-tradingview-indicator/
13. **Bailey, D. H., & López de Prado, M. (2014 & 2017) & Quant67 (1 Mayıs 2026):** *The Deflated Sharpe Ratio* & *The Probability of Backtest Overfitting* — https://www.researchgate.net/publication/286121118_The_Deflated_Sharpe_RatioCorrecting_for_Selection_Bias_BacktestOverfitting_and_Non-Normality, https://www.researchgate.net/publication/318600389_The_probability_of_backtest_overfitting ve https://quant67.com/post/quant/20-backtest-pitfalls/20-backtest-pitfalls.html
14. **Kevin Sheppard `arch` Kütüphanesi (`v7.2.0`):** *Test of Superior Predictive Ability (SPA), White's Reality Check & StepM* — https://arch.readthedocs.io/en/latest/multiple-comparison/generated/arch.bootstrap.SPA.html
15. **`skfolio` & `awesome-quant` (Mayıs–Temmuz 2026):** *Hierarchical Risk Parity, Nested Clusters Optimization & Combinatorial Purged CV* — https://skfolio.org/auto_examples/clustering/plot_4_nco.html ve https://github.com/ernie55ernie/awesome-quant
16. **Binance Data Collection (`data.binance.vision`, Ekim 2026):** *Historical Funding Rates, Open Interest, aggTrades & klines* — https://data.binance.vision/